



---

## Caracterización de datos de trayectorias individuales

*Presentado por:*  
Jorge Rafael Martínez Buenrostro

---

Asesora: Dra. Elizabeth Pérez Cortés

México, CDMX, a 6 de agosto de 2025

## Resumen

---

Una trayectoria se define como la secuencia de desplazamientos realizada por un individuo en movimiento, compuesta por tres elementos principales: **puntos de recorrido, tiempos de pausa y longitudes de vuelo**. Los puntos de recorrido corresponden a las ubicaciones o pasos específicos por los que transita el individuo. Los tiempos de pausa representan los intervalos durante los cuales el individuo permanece detenido en un mismo punto de recorrido. Por último, la longitud de vuelo se refiere a la distancia recorrida entre dos puntos de recorrido consecutivos. En el presente trabajo se describe el proceso de caraterización de datos de movilidad, es decir, el proceso de limpieza y depuración de la información, mediante el cual elimina aquellos campos y registros que no le aportan valor a la trayectoria individual. El objetivo es identificar la mayor cantidad de trayectorias individuales, para así poder crear un modelo que permita simular el movimiento de individuos.

## Contenido

---

<b>Lista de Códigos</b>	<b>IV</b>
<b>1. Introducción del Proyecto</b>	<b>1</b>
1.1. Descripción general del proyecto . . . . .	1
1.2. Objetivos y propósitos . . . . .	1
1.3. Alcance del sistema . . . . .	1
<b>2. Requisitos del sistema</b>	<b>2</b>
2.1. Requisitos . . . . .	2
2.1.1. Instrucciones de instalación . . . . .	2
<b>3. Caracterización de datos de trayectorias individuales</b>	<b>3</b>
3.1. Caracterización de datos de trayectorias individuales . . . . .	3
3.1.1. Exploración inicial del conjunto de datos . . . . .	4
3.1.2. Dimensiones del conjunto de datos . . . . .	5
3.1.3. Depuración de columnas . . . . .	5
3.1.4. Depuración de filas . . . . .	6
<b>4. Análisis del conjunto de datos</b>	<b>11</b>
4.1. Análisis del conjunto de datos . . . . .	11
<b>A. Uso de Docker y Docker Compose</b>	<b>14</b>
A.1. ¿Qué son Docker y Docker Compose? . . . . .	14
A.2. Instalación en Linux (Ubuntu/Debian) . . . . .	14
A.3. Instalación en Windows . . . . .	15
A.4. Descripción del archivo <code>docker-compose.yml</code> . . . . .	16
A.5. Scripts de control del contenedor . . . . .	18
A.5.1. <code>start_container.sh</code> . . . . .	18
A.5.2. <code>restart_container.sh</code> . . . . .	18
A.5.3. <code>stop_container.sh</code> . . . . .	19
A.6. Proceso de uso y desarrollo del contenedor . . . . .	19
<b>B. Scripts para la caracterización de datos</b>	<b>21</b>

## Lista de Figuras

---

3.1. Frecuencia de aparición de los valores de 'device_horizontal_accuracy'.	7
3.2. Frecuencia de aparición de los identificadores únicos. . . . .	7
3.3. Comparación de histogramas por rangos de repeticiones. . . . .	8
3.4. Frecuencia de aparición de los identificadores únicos después de eliminar duplicados. . . . .	9
3.5. Comparación de histogramas por rangos de repeticiones. . . . .	10
4.1. Comparación de distribución de individuos por día. . . . .	12
4.2. Distribución de individuos por días. . . . .	13

## Lista de Códigos

---

2.1. Iniciar contenedor del proyecto. . . . .	2
2.2. Iniciar contenedor del proyecto. . . . .	2
2.3. Reiniciar contenedor del proyecto. . . . .	2
A.1. Actualizar el sistema. . . . .	14
A.2. Instalar Docker. . . . .	15
A.3. Verificar instalación de Docker. . . . .	15
A.4. Instalar Docker Compose. . . . .	15
A.5. Verificar instalación de Docker Compose. . . . .	15
A.6. Verificar instalación de Docker y Docker Compose. . . . .	15
A.7. Archivo docker-compose.yml . . . . .	16
A.8. Script para iniciar el contenedor. . . . .	18
A.9. Script para reiniciar el contenedor. . . . .	18
A.10. Script para detener y eliminar el contenedor y sus volúmenes. . . . .	19
A.11. Dar permisos de ejecución a los scripts. . . . .	19
A.12. Iniciar contenedor y ejecutar el proyecto. . . . .	19
A.13. Reiniciar el contenedor completamente. . . . .	19
A.14. Eliminar el contenedor y limpiar el entorno. . . . .	19
B.1. csv_glance.py, exploración inicial del conjunto de datos. . . . .	21
B.2. csv_count_registers.py, conteo de registros en el conjunto de datos. . . . .	22
B.3. remove_columns.py, eliminación de campos innecesarios en el conjunto de datos. . . . .	23
B.4. unique_values.py, obtención de valores únicos de la columna 'device_horizontal_accuracy'. . . . .	24
B.5. accuracy_histogram.py, creación de un histograma de frecuencias de la columna 'device_horizontal_accuracy'. . . . .	26
B.6. identifier_histogram.py, creación de un histograma de frecuencias de la columna 'identifier'. . . . .	29
B.7. identifier_histogram_detailed.py, análisis de frecuencias de la columna 'identifier'. . . . .	32
B.8. csv_deduplicate.py, eliminación de duplicados en el conjunto de datos.	36
B.9. identifier_histogram_daily.py, análisis de frecuencias de la columna 'identifier' por día. . . . .	37

---

## **Capítulo 1**

### **Introducción del Proyecto**

---

#### **1.1 Descripción general del proyecto**

La simulación de una red de comunicaciones con dispositivos personales requiere modelos que representen fielmente los patrones de movimiento de las personas. De lo contrario, las conclusiones derivadas de dicha simulación pueden ser poco útiles. Para avanzar hacia la definición de un modelo de trayectorias individuales, se propone caracterizar los datos de una base existente que permita modelar trayectorias de forma eficaz.

#### **1.2 Objetivos y propósitos**

El objetivo principal del proyecto es obtener una caracterización estadística de las trayectorias individuales.

Los propósitos específicos son:

- Caracterizar la base de datos para extraer las trayectorias contenidas.
- Aplicar un modelo de inteligencia artificial para identificar y analizar dichas trayectorias.

#### **1.3 Alcance del sistema**

El sistema se enfoca en la identificación de trayectorias peatonales individuales y su análisis mediante herramientas de IA. El alcance incluye:

- Caracterización de la base de datos existente.
- Identificación de trayectorias individuales.
- Generación de reportes y visualizaciones de los resultados.

No se incluye la creación de modelos de IA desde cero; se emplearán herramientas y modelos ya existentes.

---

## Capítulo 2

### Requisitos del sistema

---

## 2.1 Requisitos

**Docker:** version 28.2.2, build e6534b4

**Docker Compose:** version 1.29.2, build unknown

### 2.1.1 Instrucciones de instalación

1. Clonar el repositorio del proyecto desde el siguiente enlace el proyecto se encuentra dentro de la carpeta **Implementación**.
2. Para levantar y acceder al contenedor, ejecutar el siguiente script:<sup>1</sup>

```
1 ./start_container.sh    # Linux/Mac  
2 .\start_container.bat  # Windows
```

Código 2.1: Iniciar contenedor del proyecto.

3. Para cerrar el contenedor del proyecto, ejecutar el siguiente script:

```
1 ./stop_container.sh    # Linux/Mac  
2 .\stop_container.bat  # Windows
```

Código 2.2: Iniciar contenedor del proyecto.

4. Para ver reflejados los cambios realizados en el código, ejecuta el siguiente script:

```
1 ./restart_container.sh  # Linux/Mac  
2 .\restart_container.bat # Windows
```

Código 2.3: Reiniciar contenedor del proyecto.

---

<sup>1</sup>Para más detalles sobre el uso de Docker y Docker Compose, consulte el Apéndice A.

---

## **Capítulo 3**

### Caracterización de datos de trayectorias individuales

---

#### **3.1 Caracterización de datos de trayectorias individuales**

El análisis de datos comienza con una etapa fundamental, la caracterización del conjunto de datos. Esta fase tiene como objetivo examinar y comprender la estructura, el contenido y las principales propiedades de los datos antes de aplicar técnicas analíticas más complejas.

En el caso de los datos de trayectorias individuales, la caracterización permite identificar posibles inconsistencias, redundancias y elementos irrelevantes que puedan afectar la calidad del análisis. Las tareas principales llevadas a cabo en esta etapa son las siguientes:

- Explorar las primeras filas del conjunto de datos para obtener una visión general de su estructura.
- Verificar la cantidad total de registros y columnas disponibles.
- Identificar y eliminar columnas que no aportan información relevante para el análisis o inconsistentes.
- Identificar y eliminar las filas que no aportan información relevante para el análisis o inconsistentes.

A continuación, se describen en detalle las acciones específicas realizadas durante el proceso de caracterización.

### 3.1.1 Exploración inicial del conjunto de datos

Como primer paso en la caracterización, se realiza una exploración preliminar del conjunto de datos con el fin de comprender su estructura general. Para ello, se inspeccionan las primeras dos filas del conjunto de datos, lo cual permite identificar las columnas presentes y observar ejemplos representativos de sus valores.

El código utilizado para realizar esta exploración se encuentra en el Apéndice B.1. A continuación, se presenta un resumen de las columnas detectadas junto con una muestra de sus respectivos valores:

1. **id**: Identificador numérico único por registro  
['34284565', '34284566']
2. **identifier**: UUID del dispositivo  
['f2640430-7e39-41b7-80bb-3fddaa44779c']
3. **identifier\_type**: Tipo de ID (ej. 'gaid' para Android)  
['gaid', 'gaid']
4. **timestamp**: Fecha-hora del registro  
['2022-11-07 02:04:21']
5. **device\_lat/device\_lon**: Coordenadas GPS  
[21.843149], [-102.196838]
6. **country\_short/province\_short**: Códigos de ubicación  
['MX'], ['MX.01']
7. **ip\_address**: Dirección IPv6  
[2806:103e:16::]
8. **device\_horizontal\_accuracy**: Precisión GPS en metros  
[8.0]
9. **source\_id**: Hash de la fuente de datos  
['449d086d...344']
10. **record\_id**: Hash único por registro  
['77d795df...']
11. **home\_country\_code**: País de residencia  
['MX']
12. **home\_geog\_point/work\_geog\_point**: Coordenadas en WKT  
['POINT(-102.37038 22.20753)']
13. **home\_hex\_id/work\_hex\_id**: ID hexagonal (H3)  
['85498853fffffff']
14. **data\_execute**: Fecha de procesamiento  
['2023-05-30']
15. **time\_zone\_name**: Zona horaria  
['America/Mexico\_City']

### 3.1.2 Dimensiones del conjunto de datos

Para verificar las dimensiones del conjunto de datos, se utiliza la biblioteca Dask, que permite trabajar con grandes volúmenes de datos de manera eficiente. Para hacer uso de esta biblioteca se usa el lenguaje de programación Python. El código del Apéndice B.2 nos da un ejemplo de su uso para esta etapa. El resultado de este script da como resultado que el conjunto de datos contiene un total de **69,980,000** registros y **19** campos. Esto indica que hay una cantidad significativa de datos disponibles para el análisis.

### 3.1.3 Depuración de columnas

Dado que el conjunto de datos original contiene 19 campos, es fundamental identificar y eliminar aquellas columnas que no aportan valor al análisis. Para ello, se realiza una revisión de los valores únicos presentes en cada campo, con el objetivo de detectar información redundante o irrelevante. A partir de este análisis, se identifican las siguientes columnas como innecesarias para los fines del estudio:

- `id`
- `identifier_type`
- `country_short`
- `province_short`
- `ip_address`
- `source_id`
- `home_country_code`
- `home_geog_point`
- `work_geog_point`
- `home_hex_id`
- `work_hex_id`
- `data_execute`

En lugar de eliminar columnas explícitamente, se opta por seleccionar únicamente aquellas que se desean conservar. El código utilizado para esta tarea se encuentra incluido en el Apéndice B.3. Dicho script emplea la biblioteca `dask` para cargar y guardar una nueva versión del conjunto de datos que contiene exclusivamente las siguientes columnas relevantes:

- `identifier`
- `timestamp`
- `device_lat`
- `device_lon`
- `device_horizontal_accuracy`

- `record_id`
- `time_zone_name`

Como resultado, se genera un nuevo archivo CSV que conserva únicamente la información útil para el análisis posterior, optimizando así el tamaño y la calidad del conjunto de datos.

### 3.1.4 Depuración de filas

Una vez obtenida una versión más ligera del conjunto de datos, el siguiente paso consiste en identificar y eliminar aquellas filas que no aportan valor al análisis. Para ello, se generan representaciones gráficas que permiten observar la distribución de los datos y facilitar la toma de decisión. Las columnas seleccionadas para este proceso fueron:

- `identifier`: Identificador único del dispositivo.
- `device_horizontal_accuracy`: Precisión del GPS en metros. A menor valor, mayor precisión.

La primera columna a analizar será `device_horizontal_accuracy`, que refleja la precisión del GPS en metros. Este valor depende tanto del sistema de medición como de la fuente de datos, y suele clasificarse según la siguiente escala:

- GPS puro (satelital): 1–20 metros.
- A-GPS (asistido por red): 5–50 metros.
- Triangulación por WiFi o redes móviles: 20–500 metros.
- Geolocalización por IP: 1000–5000 metros.

Con base en esta escala, primero hay que identificar el rango de valores presentes en la columna. Para ello se utiliza el código mostrado en el Apéndice B.4, el cual extrae los valores únicos de `device_horizontal_accuracy` y los guarda en un archivo de texto. El resultado indica que los valores oscilan entre 0.916 y 199.9, lo que permite construir un histograma (Apéndice B.5) para analizar la frecuencia de cada valor y así evaluar su relevancia para el análisis. El resultado se muestra en la siguiente figura:

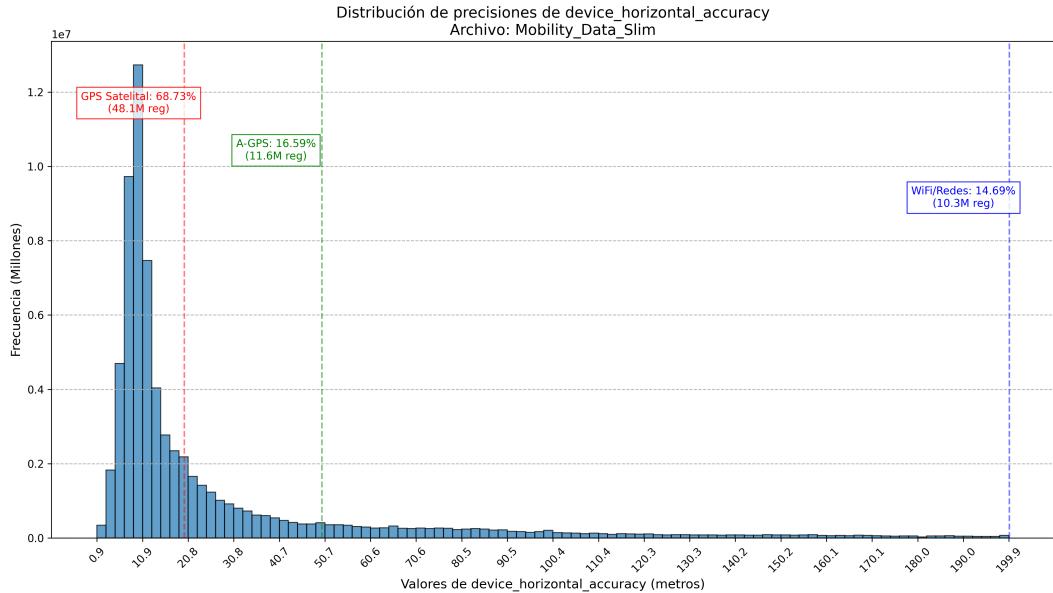


Figura 3.1: Frecuencia de aparición de los valores de 'device\_horizontal\_accuracy'.

Para el objetivo de este proyecto, se busca que la configuración del GPS sea lo más precisa posible, por lo que aquellos que estén dentro del rango del GPS puro (1-20 metros) son los más relevantes. Como se puede ver en la Figura 3.1, el **68.73 %** de los valores se encuentran dentro de este rango. Sin embargo, el **31.27 %** de registros con están por encima de este rango, precisión A-GPS (5-50 metros) y triangulación por WiFi/red móvil (20-500 metros).

La siguiente columna a evaluar es **identifier**, corresponde al identificador único de cada dispositivo. Para analizar la frecuencia de aparición de estos valores se emplea un script que agrupa las repeticiones por rangos y grafica la cantidad de valores únicos usando escala logarítmica (ver Apéndice B.6).

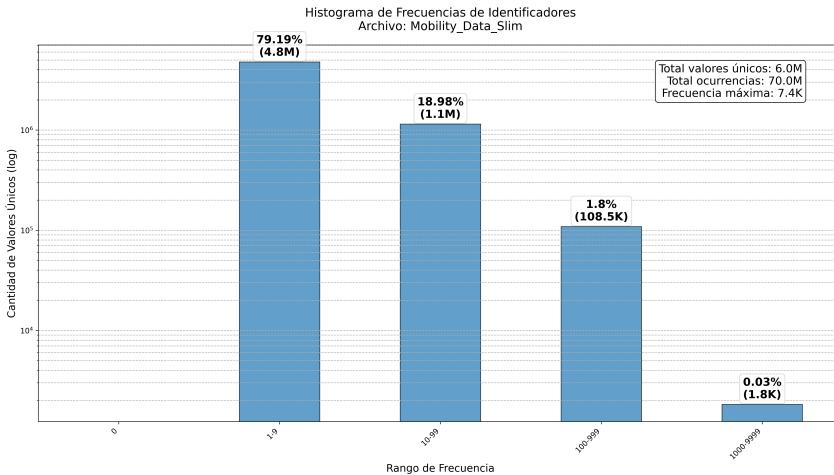


Figura 3.2: Frecuencia de aparición de los identificadores únicos.

Ejecutar este script permite saber que el total de individuos es de **6,022,772** de los cuales el **79.19 %** tienen una frecuencia de aparición de una a nueve veces, esto es **4,769,317** de individuos. Así mismo de la Figura 3.2 se observa que hay poco más de un **20 %** de individuos con más de 99 repeticiones. Por lo que se necesita hacer un análisis más detallado, para ello se ejecuta el código del Apéndice B.7, el cual segmenta los datos en tres rangos: 1-99, 100-1000 y 1001-10000 repeticiones.

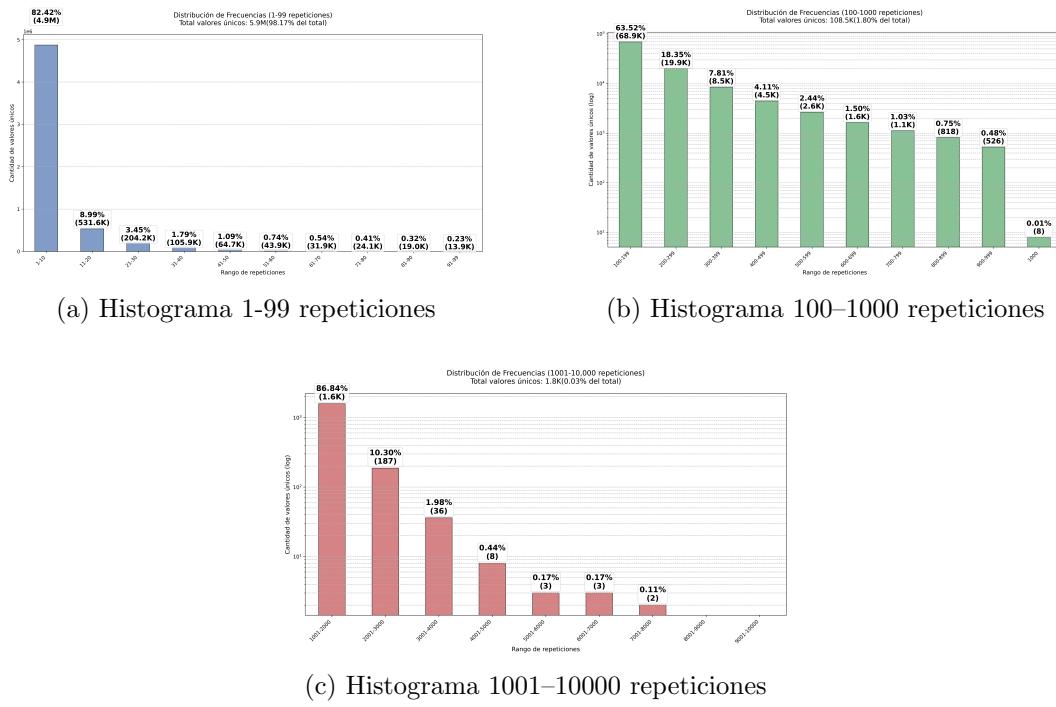


Figura 3.3: Comparación de histogramas por rangos de repeticiones.

Con la información obtenida de los histogramas de la figura anterior, se puede observar que el **98.17 %** de los identificadores únicos tienen entre 1 y 99 repeticiones, lo que equivale a **5,912,437** individuos. Por otro lado, el **1.83 %** restante tiene entre 100 y 10,000 repeticiones, lo que equivale a **110,335** individuos. Con base en esta información aún no se puede determinar que registros eliminar.

Por lo que el siguiente paso consiste en eliminar aquellos registros duplicados, es decir, aquellos que tengan el mismo valor en las columnas: `identifier`, `timestamp`, `device_lat` y `device_lon`. Para ello se utiliza el código del Apéndice B.8, que elimina los duplicados y genera un nuevo archivo CSV con los registros de individuos.

Con este nuevo archivo se vuelve a realizar el análisis de frecuencia de aparición de individuos. En la siguiente figura se muestra el histograma de la frecuencia de aparición de los identificadores únicos

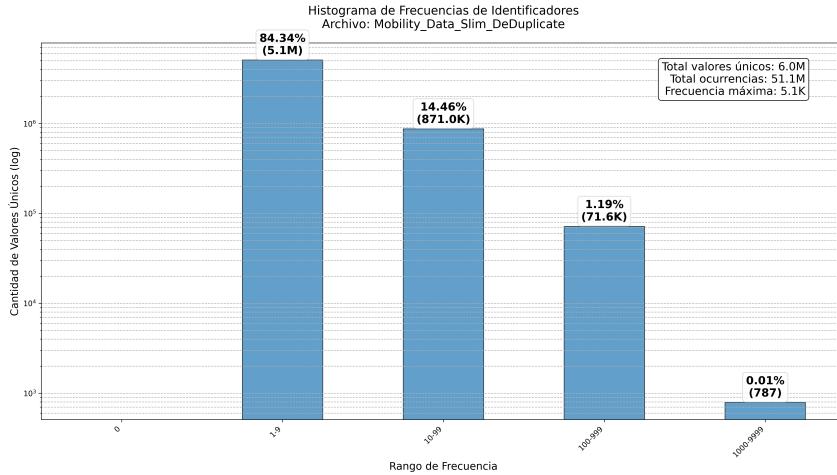



Figura 3.4: Frecuencia de aparición de los identificadores únicos después de eliminar duplicados.

Comparando los resultados de la Figura 3.2 y la Figura 3.4 podemos destacar varios hallazgos importantes:


- El número de individuos (**6,022,772**) se mantuvo sin cambios.
- La eliminación del **27 %** de registros. De **70 millones** a **51 millones** de registros.
- La reducción del **31.1 %** en la frecuencia máxima de aparición (de 7,400 a 5,100) corrige sesgos que afectaban especialmente a individuos con alta frecuencia de registros repetidos.

De la Figura 3.5 se puede observar que la distribución de los individuos se mantiene similar; sin embargo, ahora el número de individuos que tienen entre 1 y 99 repeticiones aumentó del **98.17 %** al **98.8 %**, lo que equivale a un aumento de **37,899** individuos. Por otro lado, el número de individuos con más de 100 repeticiones bajó del **1.83 %** al **1.2 %**, lo que equivale a una disminución de **37,899** individuos, lo que sugiere que la mayoría de los individuos no generan datos de manera continua o frecuente. Sin embargo, es importante destacar que al eliminar aquellos puntos de recorrido duplicados por individuo permite asumir que los puntos de recorrido restantes son más representativos de la movilidad real de los individuos.


Dado los resultados obtenidos en esta etapa de la caracterización, se concluye que no es necesario eliminar ninguna fila del conjunto de datos, ya que la depuración de columnas y la eliminación de duplicados han sido suficientes para optimizar la calidad del conjunto de datos.



(a) Histograma 1-99 repeticiones



(b) Histograma 100-1000 repeticiones



(c) Histograma 1001-10000 repeticiones


Figura 3.5: Comparación de histogramas por rangos de repeticiones.

## Capítulo 4

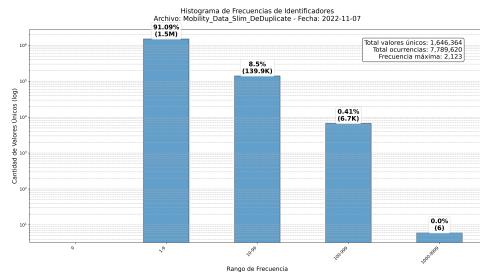
### Análisis del conjunto de datos

#### 4.1 Análisis del conjunto de datos


En esta sección se presenta un análisis detallado del conjunto de datos, que incluye la identificación de patrones y tendencias en las trayectorias individuales. El conjunto de datos contiene puntos de recorrido obtenidos a lo largo de diez días. Por lo que el primer acercamiento del análisis es poder ver la distribución de los puntos de recorrido en cada día registrado por medio un histograma por día. Para crear estos historogramas se ejecuta el código del Apéndice B.9. A continuación, se muestran estos histogramas.



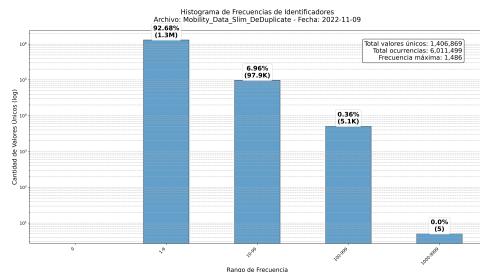
(a) Histograma del 06/Nov/2022



(b) Histograma del 07/Nov/2022



(c) Histograma del 08/Nov/2022



(d) Histograma del 09/Nov/2022

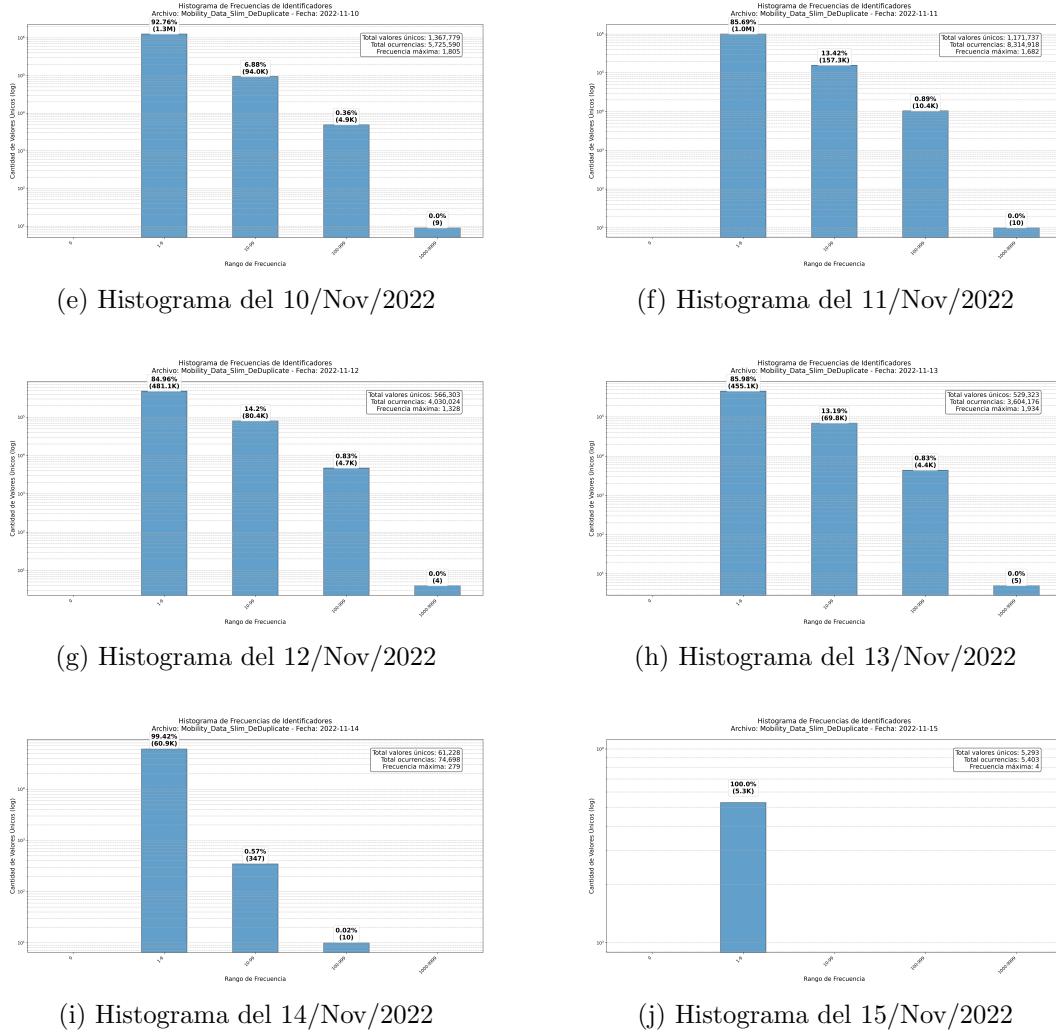


Figura 4.1: Comparación de distribución de individuos por día.

De la figura anterior se puede observar que la distribución de individuos por día es bastante similar a la distribución vista en la Figura 3.4, donde se observa que la mayoría de los individuos tienen una frecuencia de aparición baja. Además se puede ver que los primeros seis días hay en promedio **1,400,000** de individuos, mientras que los últimos cuatro días este valor va disminuyendo hasta llegar a **5,293** individuos el día 15 de noviembre. Esto puede ser un indicativo de que la recolección de datos no fue constante a lo largo del tiempo, lo que podría deberse a diversos factores como problemas técnicos o cambios en el comportamiento de los individuos.

Un patrón que puede dar mucha información es determinar cuantos individuos tienen puntos de recorrido en más de un día. Para esto se ejecuta el código del Apéndice




Figura 4.2: Distribución de individuos por días.

## Apéndice A

### Uso de Docker y Docker Compose

---

En la sección 2.1 se establece como requisito el uso de Docker y Docker Compose para la ejecución del proyecto. A continuación, se detallan las instrucciones necesarias para su instalación, ya que ambas herramientas son fundamentales para la implementación. Además, se describe el archivo `docker-compose.yml`, el cual permite crear un contenedor que incluye todas las dependencias requeridas para el correcto funcionamiento del sistema.

#### A.1 ¿Qué son Docker y Docker Compose?

Docker es una plataforma de virtualización ligera que permite desarrollar, empaquetar y ejecutar aplicaciones en contenedores aislados. Un contenedor incluye el código, las dependencias y configuraciones necesarias para que la aplicación se ejecute de manera consistente en cualquier entorno. Esto facilita la portabilidad, escalabilidad y despliegue de software.

Docker Compose es una herramienta que permite definir y ejecutar aplicaciones multicontenedor mediante archivos de configuración YAML. A través de un solo archivo `docker-compose.yml`, es posible especificar los servicios, redes y volúmenes que componen una aplicación, simplificando así su orquestación.

Estas herramientas son fundamentales en este proyecto para garantizar que el entorno de ejecución sea replicable y controlado, independientemente del sistema operativo o configuración local del usuario.

#### A.2 Instalación en Linux (Ubuntu/Debian)

Para instalar Docker y Docker Compose en un sistema Linux basado en Debian o Ubuntu, siga los siguientes pasos:

1. Actualizar los paquetes del sistema:

```
1 sudo apt update  
2 sudo apt upgrade
```

Código A.1: Actualizar el sistema.

2. Instalar Docker:

```
1 sudo apt install docker.io
2 sudo systemctl enable docker
3 sudo systemctl start docker
```

Código A.2: Instalar Docker.

3. Verificar que Docker está instalado correctamente:

```
1 docker --version
```

Código A.3: Verificar instalación de Docker.

4. Instalar Docker Compose:

```
1 sudo apt install docker-compose
```

Código A.4: Instalar Docker Compose.

5. Verificar la instalación:

```
1 docker-compose --version
```

Código A.5: Verificar instalación de Docker Compose.

### A.3 Instalación en Windows

Para instalar Docker y Docker Compose en Windows, se recomienda utilizar Docker Desktop, que incluye ambas herramientas de forma integrada.

1. Acceder al sitio oficial: <https://www.docker.com/products/docker-desktop/>
2. Descargar el instalador correspondiente para Windows.
3. Ejecutar el instalador y seguir el asistente de instalación.
4. Reiniciar el sistema si es necesario.
5. Verificar que Docker y Docker Compose estén correctamente instalados desde la terminal de Windows (PowerShell o CMD):

```
1 docker --version
2 docker-compose --version
```

Código A.6: Verificar instalación de Docker y Docker Compose.

**Nota:** Docker Desktop requiere que la virtualización esté habilitada en la BIOS del sistema. También es necesario contar con Windows 10 o superior.

## A.4 Descripción del archivo docker-compose.yml

El archivo `docker-compose.yml` permite definir y configurar el entorno de ejecución del proyecto utilizando un contenedor de Docker. A continuación, se presenta su contenido y una explicación de cada uno de sus elementos:

```
1 version: "3.8"
2
3 services:
4   data-analysis:
5     image: python:3.13-bookworm
6     container_name: data-analysis
7     runtime: nvidia
8     tty: true
9     stdin_open: true
10    volumes:
11      - ./:/app
12      - python-packages:/usr/local/lib/python3.13/site-packages
13    command: sh -c "pip\u00a9install\u00a9r\u00a9requirements.txt\u00a9&&\u00a9pip\u00a9
14      install\u00a9e\u00a9&&\u00a9python3\u00a9/app/src/main.py"
15    working_dir: /app
16    environment:
17      - PYTHONPATH=/app
18
19 volumes:
  python-packages:
```

Código A.7: Archivo docker-compose.yml

A continuación se explica el propósito de cada sección:

- **version: "3.8"**

Define la versión del esquema de Docker Compose utilizado. La versión 3.8 es compatible con la mayoría de las características modernas de Docker.

- **services → data-analysis**

Se define un servicio llamado `data-analysis`, que representa el contenedor principal del proyecto.

- **image: python:3.13-bookworm**

Utiliza una imagen oficial de Python 3.13 basada en Debian Bookworm como entorno base.

- **container\_name: data-analysis**

Asigna un nombre personalizado al contenedor para facilitar su identificación.

- **runtime: nvidia**

Indica que el contenedor utilizará el runtime de NVIDIA para permitir acceso a la GPU. Requiere tener instalado `nvidia-docker`.

- **tty: true y stdin\_open: true**

Habilitan la interacción con el terminal del contenedor, lo que es útil para

ejecutar comandos manuales si es necesario.

- **volumes**

- `./:/app`: Monta el directorio actual del proyecto como `/app` dentro del contenedor.
- `python-packages:/usr/local/lib/python3.13/site-packages`: Crea un volumen persistente para las bibliotecas de Python instaladas.

- **command**

Ejecuta una serie de comandos cuando el contenedor inicia: instala las dependencias del archivo `requirements.txt`, instala el proyecto en modo editable (`pip install -e .`) y ejecuta el archivo `main.py`.

- **working\_dir: /app**

Establece el directorio de trabajo dentro del contenedor como `/app`.

- **environment**

Define la variable de entorno `PYTHONPATH` para que Python pueda encontrar correctamente los módulos dentro del proyecto.

- **volumes → python-packages**

Declara un volumen persistente llamado `python-packages`, que se utiliza para almacenar los paquetes instalados sin perderlos entre reinicios del contenedor.

Este archivo permite que el entorno de desarrollo sea fácilmente replicable y ejecutable, sin necesidad de instalar manualmente dependencias o configurar rutas en el sistema anfitrión.

## A.5 Scripts de control del contenedor

Para facilitar el manejo del contenedor durante el desarrollo del proyecto, se han creado tres scripts auxiliares en Bash que automatizan las operaciones más comunes: iniciar, reiniciar y detener el contenedor.

### A.5.1 start\_container.sh

Este script verifica si el contenedor `data-analysis` ya se encuentra en ejecución. En caso de que no esté activo, lo inicia utilizando `docker-compose up -d`. Posteriormente, ejecuta el archivo `main.py` dentro del contenedor.

```

1 #!/bin/bash
2
3 if ! docker ps --filter "name=/data-analysis$" --filter "
4   status=running" | grep -q data-analysis; then
5   echo "Contenedor no está corriendo. Levantando con docker-
6     compose..."
7   docker-compose up -d
8   echo "Esperando que se instalen las dependencias..."
9   while ! docker exec data-analysis pip show colorama &> /dev
10    /null; do
11      sleep 2
12    done
13    echo "Dependencias instaladas correctamente."
14 else
15   echo "Contenedor ya está corriendo. Usando instancia_
16     existente."
17 fi
18
19 echo "Ejecutando script..."
20 docker exec -it data-analysis python3 /app/src/main.py

```

Código A.8: Script para iniciar el contenedor.

### A.5.2 restart\_container.sh

Este script reinicia completamente el contenedor (equivalente a detenerlo y volverlo a levantar), lo cual resulta útil cuando se han modificado archivos como `requirements.txt` o `setup.py`. Tras reiniciar, vuelve a ejecutar el archivo principal del proyecto.

```

1 #!/bin/bash
2 docker restart data-analysis
3 sleep 2
4 docker exec -it data-analysis python3 /app/src/main.py

```

Código A.9: Script para reiniciar el contenedor.

### A.5.3 stop\_container.sh

Este script detiene y elimina el contenedor junto con los volúmenes asociados. Debe utilizarse con precaución, ya que elimina todas las dependencias instaladas en el entorno del contenedor. Solo es necesario en casos donde se requiere limpiar completamente el entorno.

```
1 #!/bin/bash  
2 docker-compose down --volumes
```

Código A.10: Script para detener y eliminar el contenedor y sus volúmenes.

## A.6 Proceso de uso y desarrollo del contenedor

A continuación se describe el flujo recomendado para desarrollar y ejecutar el sistema dentro del contenedor de Docker:

1. Verifique que Docker y Docker Compose están instalados (Apéndice A.6).

**Nota para usuarios de Windows:** Si se utiliza Windows como sistema operativo, se deben usar los archivos con extensión **.bat** en lugar de **.sh**, y deben ser ejecutados desde la terminal de Windows (por ejemplo, CMD o PowerShell).

2. Asigne permisos de ejecución a los scripts:

```
1 chmod +x start_container.sh restart_container.sh  
      stop_container.sh
```

Código A.11: Dar permisos de ejecución a los scripts.

3. Para iniciar el contenedor y ejecutar el proyecto con los cambios más recientes del código fuente:

```
1 ./start_container.sh
```

Código A.12: Iniciar contenedor y ejecutar el proyecto.

4. Si se realizan cambios en las dependencias o archivos de configuración del entorno (como **requirements.txt**), utilice:

```
1 ./restart_container.sh
```

Código A.13: Reiniciar el contenedor completamente.

5. Para detener el contenedor y eliminar todos los volúmenes asociados:

```
1 ./stop_container.sh
```

Código A.14: Eliminar el contenedor y limpiar el entorno.

Este conjunto de scripts permite un desarrollo ágil dentro del contenedor, ya que los cambios realizados en el código fuente local se reflejan de inmediato gracias al uso de **volumes**. Además, se reduce la necesidad de ejecutar manualmente comandos repetitivos, facilitando el trabajo del usuario final y asegurando la correcta ejecución del proyecto.

## Apéndice B

### Scripts para la caracterización de datos

---

En la sección 3.1 se describen los pasos del proceso de caracterización de datos de trayectorias individuales. En este anexo se presentan los scripts utilizados para llevar a cabo dicho proceso.

```
1 import dask.dataframe as dd
2 import sys
3
4 print("Exploracion\u00ed inicial\u00ed de\u00ed datos\u00ed con\u00ed Dask\n")
5
6 if len(sys.argv) < 2:
7     print("Error:\u00d3 Debe\u00f1 especificar\u00ed un\u00d3 archivo\u00d3 CSV")
8     sys.exit(1)
9
10 ruta_archivo = sys.argv[1]
11
12 ddf = dd.read_csv(
13     ruta_archivo,
14     encoding="utf-8",
15     sep=",",
16     dtype="object",
17 )
18
19 columnas = ddf.columns.tolist()
20
21 print("Columnas\u00d3 y\u00d3 2\u00d3 ejemplos\u00d3 por\u00d1 cada\u00d3 una:\n")
22 for col in columnas:
23     ejemplos = ddf[col].head(2).values.tolist()
24     print(f"-{col}: {ejemplos}")
25
26 input("Presiona\u00d3 Enter\u00d3 para\u00d1 continuar...")
```

Código B.1: csv\_glance.py, exploración inicial del conjunto de datos.

```
1 import dask.dataframe as dd
2 import sys
3 import os
4
5 def contar_registros(ruta_archivo):
6
7     columnas_usar = ["record_id"]
8     try:
9         print(f"\nCargando archivo {ruta_archivo}...")
10        ddf = dd.read_csv(
11            ruta_archivo,
12            usecols=columnas_usar,
13            sep=",",
14            dtype={"record_id": "str"},
15            blocksize="256MB",
16        )
17
18        print("Contando registros (pacienza para archivos grandes)...")
19        total_registros = ddf.shape[0].compute()
20
21        print("\nAnalisis completado:")
22        print(f"Archivo analizado: {ruta_archivo}")
23        print(f"Total de registros: {total_registros:,}")
24
25    except Exception as e:
26        print(f"\nOcurrio un error inesperado: {str(e)}")
27
28 if __name__ == "__main__":
29     print("== Contador de registros en archivos CSV grandes ==")
30
31     if len(sys.argv) < 2:
32         print("Uso: python csv_count_registers.py < nombre_del_archivo.csv >")
33         sys.exit(1)
34
35     archivo = sys.argv[1]
36     contar_registros(archivo)
```

Código B.2: csv\_count\_registers.py, conteo de registros en el conjunto de datos.

```
1 import dask.dataframe as dd
2
3 columnas_deseadas = [
4     'identifier',
5     'timestamp',
6     'device_lat',
7     'device_lon',
8     'device_horizontal_accuracy',
9     'record_id',
10    'time_zone_name'
11]
12
13 df = dd.read_csv('Mobility_Data.csv', usecols=
14    columnas_deseadas)
15 df.to_csv('Mobility_Data_Slim.csv', index=False, single_file=
16    True, encoding='utf-8-sig')
```

Código B.3: remove\_columns.py, eliminación de campos innecesarios en el conjunto de datos.

```
1  import pandas as pd
2  from tqdm import tqdm
3  import os
4  import sys
5  from src.menus.menu import MainMenu
6  def main():
7      print("\n" + "*50)
8      print("EXTRACTOR DE VALORES UNICOS DE COLUMNAS CSV")
9      print("*50 + "\n")
10
11     if len(sys.argv) < 2:
12         print("Uso: python extract_unique.py <archivo.csv>")
13         sys.exit(1)
14
15     csv_file = sys.argv[1]
16
17     if not os.path.exists(csv_file):
18         print(f"Error: El archivo '{csv_file}' no existe.")
19         sys.exit(1)
20
21     chunk_size = 1_000_000
22
23     try:
24         available_columns = pd.read_csv(csv_file, nrows=0).
25             columns.tolist()
26     except Exception as e:
27         print(f"Error leyendo el archivo: {e}")
28         sys.exit(1)
29
30     try:
31         selected_index = MainMenu.display_available_columns(
32             available_columns)
33         target_column = available_columns[selected_index]
34     except (ValueError, IndexError):
35         print("Seleccion invalida.")
36         sys.exit(1)
37     except Exception as e:
38         print(f"Error inesperado al seleccionar columna: {e}")
39         sys.exit(1)
40
41     safe_column_name = target_column.replace(" ", "_").
42         replace("/", "_")
43     output_file = f"valores_unicos_{safe_column_name}.txt"
44
45     unique_values = set()
46     print(f"\nProcesando columna: {target_column}\n")
47
48     try:
49         for chunk in tqdm(pd.read_csv(csv_file, usecols=[
```

```
47         target_column], chunksize=chunk_size)):
48             unique_values.update(chunk[target_column].dropna()
49                 ().astype(str))
50     except Exception as e:
51         print(f"Error durante el procesamiento: {e}")
52         sys.exit(1)
53
54     try:
55         numeric_values = sorted([float(v) for v in
56             unique_values])
57         is_numeric = True
58     except ValueError:
59         is_numeric = False
60
61     try:
62         with open(output_file, "w", encoding="utf-8") as f:
63             if is_numeric:
64                 min_val = numeric_values[0]
65                 max_val = numeric_values[-1]
66                 f.write(f"# Rango de valores: {min_val}-{max_val}\n")
67                 f.write("\n".join(str(v) for v in
68                     numeric_values))
69             else:
70                 sorted_values = sorted(unique_values)
71                 f.write("# Rango de valores: No numerico\n")
72                 f.write("\n".join(sorted_values))
73     except Exception as e:
74         print(f"Error guardando los resultados: {e}")
75         sys.exit(1)
76
77     print(f"\nSe encontraron {len(unique_values)} valores únicos.")
78     print(f"Resultados guardados en: {output_file}")
79
80     print("\nMuestra de valores únicos (primeros 10):")
81     print("\n".join(sorted(unique_values)[:10]))
82
83 if __name__ == "__main__":
84     main()
```

Código B.4: unique\_values.py, obtención de valores únicos de la columna 'device\_horizontal\_accuracy'.

```
1     import os
2     import pandas as pd
3     import matplotlib.pyplot as plt
4     import numpy as np
5     import sys
6     from tqdm import tqdm
7
8     def classify_tech(valor):
9         if 1 <= valor <= 20:
10             return 'GPS\u201dSatelital'
11         elif 5 <= valor <= 50:
12             return 'A-GPS\u201d(Asistido\u201dpor\u201dred)'
13         elif 20 <= valor <= 500:
14             return 'Triangulacion\u201dWiFi/Redes\u201dMoviles'
15         else:
16             return 'Fuera\u201dde\u201drango'
17
18     def format_count(count):
19         if count >= 1_000_000:
20             return f"{count/1_000_000:.1f}M"
21         elif count >= 1_000:
22             return f"{count/1_000:.1f}K"
23         return str(count)
24
25     def main():
26         if len(sys.argv) < 2:
27             print("Error:\u201dDebe\u201despecificar\u201dun\u201darchivo\u201dCSV\u201dcomo\u201dargumento")
28             sys.exit(1)
29
30         csv_file = sys.argv[1]
31         filename = os.path.splitext(os.path.basename(csv_file))
32         [0]
33         column = "device_horizontal_accuracy"
34         bins = 100
35
36         print(f"\nIniciando\u201dprocesamiento\u201ddel\u201darchivo:\u201d{csv_file}\u201d")
37         print(f"Columna\u201danalizada:\u201d{column}\u201d")
38
39         os.makedirs("img", exist_ok=True)
40         print("Directorio\u201d'img'\u201dverificado/creado")
41
42         print("\nProcesando\u201ddatos\u201dy\u201dclasificando\u201dtecnologias...")
43         frequency = pd.Series(dtype=float)
44         tech_counts = {
45             'GPS\u201dSatelital': 0,
46             'A-GPS\u201d(Asistido\u201dpor\u201dred)': 0,
47             'Triangulacion\u201dWiFi/Redes\u201dMoviles': 0,
```

```
47         'Fuera_de_rango': 0
48     }
49
50     total_row = sum(1 for _ in pd.read_csv(csv_file,
51                     usecols=[column], chunksize=1_000_000))
52
53     with tqdm(total=total_row, unit='M_rows') as pbar:
54         for chunk in pd.read_csv(csv_file, usecols=[column],
55             chunksize=1_000_000):
56             chunk_clean = chunk[column].dropna()
57
58             for valor in chunk_clean:
59                 tech = classify_tech(valor)
60                 tech_counts[tech] += 1
61
62                 counts = chunk_clean.value_counts()
63                 if not frequency.empty or not counts.empty:
64                     frequency = pd.concat([frequency, counts],
65                         axis=0).groupby(level=0).sum()
66                     pbar.update(1)
67
68             total = sum(tech_counts.values())
69             percentage = {k: (v/total)*100 for k, v in tech_counts.
70                           items()}
71
72             print("\nGenerando histograma con estadísticas...")
73             counts, edges = np.histogram(frequency.index, bins=bins,
74                 weights=frequency.values)
75
76             plt.figure(figsize=(14, 8))
77             plt.bar(edges[:-1], counts, width=np.diff(edges), align
78                     ='edge', edgecolor='black', alpha=0.7)
79
80             plt.axvline(x=20, color='r', linestyle='--', alpha=0.5)
81             plt.axvline(x=50, color='g', linestyle='--', alpha=0.5)
82             plt.axvline(x=200, color='b', linestyle='--', alpha
83                     =0.5)
84
85             gps_str = f"GPS_Satelital:{percentage['GPS_Satelital
86                 ']:.2f}\n({format_count(tech_counts['GPS_Satelital
87                 '])})\n"
88             agps_str = f"A-GPS:{percentage['A-GPS_(Asistido_por_
89                 red)']:.2f}\n({format_count(tech_counts['A-GPS_(
90                 Asistido_por_red)'])})\n"
91             wifi_str = f"WiFi/Redes:{percentage['Triangulacion_
92                 WiFi/Redes_Moviles']:.2f}\n({format_count(
93                 tech_counts['Triangulacion_WIFI/Redes_Moviles'])})\n"
94
95             plt.text(10, max(counts)*0.9, gps_str, ha='center',
96                     color='r', fontsize=10,
```

```

83         bbox=dict(facecolor='white', alpha=0.8,
84             edgecolor='r'))
85     plt.text(40, max(counts)*0.8, agps_str, ha='center',
86             color='g', fontsize=10,
87             bbox=dict(facecolor='white', alpha=0.8,
88                 edgecolor='g'))
89
90     plt.title(f"Distribucion de precisiones de {column}\n"
91               f"nArchivo:{filename}", fontsize=14)
92     plt.xlabel(f"Valores de {column} (metros)", fontsize
93                =12)
94     plt.ylabel("Frecuencia (Millones)", fontsize=12)
95     plt.xticks(edges[::5], rotation=45)
96     plt.grid(axis='y', linestyle='--')
97     plt.tight_layout()
98
99     output_path = os.path.join("img", f"histograma_{column}_"
100                                f"{filename}.png")
101    plt.savefig(output_path, dpi=300, bbox_inches='tight')
102    plt.close()
103
104   print("\n==== DISTRIBUCION DE TECNOLOGIAS DE "
105         "GEOLOCALIZACION ===")
106   for tech, count in tech_counts.items():
107       print(f'{tech}:{count:,} registros ({percentage['
108           f'tech]:.2f}%)')
109
110   print(f'\nHistograma generado exitosamente')
111   print(f'Archivo guardado en: {output_path}')
112   print(f'Total registros analizados: {total:,}\n')
113
114   if __name__ == "__main__":
115       main()

```

Código B.5: accuracy\_histogram.py, creación de un histograma de frecuencias de la columna 'device\_horizontal\_accuracy'.

```
1  import os
2  import pandas as pd
3  import matplotlib.pyplot as plt
4  import numpy as np
5  from collections import Counter
6  import sys
7  from tqdm import tqdm
8  import math
9
10 def format_count(count):
11     if count >= 1_000_000:
12         return f"{count/1_000_000:.1f}M"
13     elif count >= 1_000:
14         return f"{count/1_000:.1f}K"
15     return str(count)
16
17 def main():
18     if len(sys.argv) < 2:
19         print("Error: Debe especificar un archivo CSV como argumento")
20         sys.exit(1)
21
22     csv_file = sys.argv[1]
23     filename = os.path.splitext(os.path.basename(csv_file))[0]
24     column = "identifier"
25     chunksize = 1_000_000
26
27     print(f"\nIniciando procesamiento del archivo: {csv_file}")
28     print(f"Columna analizada: {column}")
29     os.makedirs("img", exist_ok=True)
30     print("Directorio 'img' verificado/creado")
31
32     print("\nProcesando datos y contando frecuencias...")
33     counter = Counter()
34
35     total_chunks = sum(1 for _ in pd.read_csv(csv_file,
36                         usecols=[column], chunksize=chunksize))
37
38     with tqdm(total=total_chunks, unit='chunk') as pbar:
39         for chunk in pd.read_csv(csv_file, usecols=[column],
40                               chunksize=chunksize):
41             counter.update(chunk[column].dropna().astype(str))
42             pbar.update(1)
43
44     frecuency = pd.Series(counter)
45     total_unique_values = len(frecuency)
46     max_freq = frecuency.max()
```

```
45      print(f"Datos procesados correctamente")
46      print(f"Total de valores Unicos:{total_unique_values
47          : , }")
48      print(f"Frecuencia maxima:{max_freq:, }")
49
50      bins = [0] + [10**i for i in range(0, int(np.log10(
51          max_freq)) + 2)]
52      group_freq = pd.cut(frecuency, bins=bins, right=False).
53          value_counts().sort_index()
54
55      total_occurrence = frecuency.sum()
56      percentage_per_range = (group_freq /
57          total_unique_values * 100).round(2)
58
59      print("\nGenerando histograma con estadisticas...")
60      plt.figure(figsize=(16, 9))
61      ax = group_freq.plot(kind='bar', logy=True, alpha=0.7,
62          edgecolor='black')
63
64      formated_labels = []
65      for interval in group_freq.index.categories:
66          left = int(interval.left)
67          right = int(interval.right - 1)
68          formated_labels.append(f"{left}-{right}" if left
69              != right else f"{left}")
70
71      plt.xticks(range(len(formated_labels)),
72          formated_labels, rotation=45, ha='right')
73
74      plt.title(f"Histograma de Frecuencias de
75          Identificadores\nArchivo:{filename}", fontsize=16,
76          pad=20)
77      plt.xlabel("Rango de Frecuencia", fontsize=14)
78      plt.ylabel("Cantidad de Valores Unicos(log)", fontsize
79          =14)
80      plt.grid(True, which="both", ls="--", axis='y')
81
82      stats_text = (
83          f"Total_valores_unicos:{format_count(
84              total_unique_values)}\n"
85          f"Total_ocurrencias:{format_count(total_occurrence)
86              }\n"
87          f"Frecuencia_maxima:{format_count(max_freq)}"
88      )
89      plt.annotate(stats_text,
90          xy=(0.95, 0.95),
91          xycoords='axes fraction',
92          fontsize=15,
93          ha='right',
94          va='top',
```

```

84         bbox=dict(boxstyle='round', facecolor='
85             white', alpha=0.9))
86
87     max_val = group_freq.max()
88     min_y = 0.9
89
90     for i, (count, porcent) in enumerate(zip(group_freq.
91         values, percentage_per_range.values)):
92         if count > 0:
93             y_pos = count * 1.1 if count * 1.1 > min_y else
94                 min_y * 1.2
95
96             text = f'{porcent}%\n{format_count(count)}'
97
98             ax.text(
99                 i, y_pos, text,
100                 ha='center', va='bottom',
101                 fontsize=15,
102                 fontweight='bold',
103                 bbox=dict(
104                     facecolor='white',
105                     alpha=0.85,
106                     edgecolor='lightgray',
107                     boxstyle='round', pad=0.3
108                 )
109             )
110
111     output_path = os.path.join("img", f"histograma_{column}
112         _{filename}.png")
113     plt.tight_layout()
114     plt.savefig(output_path, dpi=300, bbox_inches='tight')
115     plt.close()
116
117     print("\n==== DISTRIBUCION DE FRECUENCIAS ====")
118     for i, (intervalo, count) in enumerate(group_freq.items
119         ()):
120         print(f"Rango {formatted_labels[i]}: {count},")
121
122         print(f"\nHistograma generado exitosamente")
123         print(f"Archivo guardado en: {output_path}")
124         print(f"Total ocurrencias analizadas: {total_occurrence
125             :,}\n")
126
127     if __name__ == "__main__":
128         main()

```

Código B.6: identifier\_histogram.py, creación de un histograma de frecuencias de la columna 'identifier'.

```
1 import os
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 import numpy as np
5 from collections import Counter
6 import sys
7 from tqdm import tqdm
8
9 def format_count(count):
10     if count >= 1_000_000:
11         return f"{count/1_000_000:.1f}M"
12     elif count >= 1_000:
13         return f"{count/1_000:.1f}K"
14     return str(count)
15
16 def create_histogram(data, bins, title, filename, color='skyblue', log_scale=False):
17     grouped = pd.cut(data, bins=bins, right=False).
18         value_counts().sort_index()
19     total_values = len(data)
20     max_count = grouped.max()
21
22     plt.figure(figsize=(14, 8))
23     ax = grouped.plot(kind='bar', color=color, edgecolor='black', alpha=0.7, logy=log_scale)
24
25     bin_labels = []
26     for interval in grouped.index.categories:
27         left = int(interval.left)
28         right = int(interval.right)
29         bin_labels.append(f'{left}-{right-1}' if right-left
30                           > 1 else str(left))
31
32     plt.xticks(range(len(bin_labels)), bin_labels, rotation
33                =45, ha='right')
34     plt.title(f'{title}\nTotal_valores_unicos:{format_count(total_values)}', fontsize=14, pad=20)
35     plt.xlabel("Rango_de_repeticiones", fontsize=12)
36     plt.ylabel("Cantidad_de_valores_unicos" + ("_(log)" if
37             log_scale else ""), fontsize=12)
38     plt.grid(True, which="both", ls="--", axis='y')
39
40     min_y = 0.9
41     for i, (count, interval) in enumerate(zip(grouped.
42         values, grouped.index)):
43         if count > 0:
44             percentage = (count / total_values) * 100
45             y_pos = count * 1.1 if count * 1.1 > min_y else
46                 min_y * 1.2
47             text = f'{percentage:.2f}%\n{format_count(
```

```
        count)})"

42
43     ax.text(i, y_pos, text,
44             ha='center', va='bottom',
45             fontsize=15, fontweight='bold',
46             bbox=dict(facecolor='white', alpha=0.8,
47                       edgecolor='lightgray', boxstyle='round',
48                       pad=0.2))

49
50     output_path = os.path.join("img", filename)
51     plt.tight_layout()
52     plt.savefig(output_path, dpi=300, bbox_inches='tight')
53     plt.close()
54     return output_path

55 def main():
56     if len(sys.argv) < 2:
57         print("Error: Debe especificar un archivo CSV")
58         sys.exit(1)

59     csv_file = sys.argv[1]
60     filename_base = os.path.splitext(os.path.basename(
61         csv_file))[0]
62     column = "identifier"
63     chunksize = 1_000_000
64     os.makedirs("img", exist_ok=True)

65     print(f"\nIniciando análisis de: {csv_file}")
66     print(f"Columna analizada: {column}")

67     print("\nContando frecuencias...")
68     counter = Counter()

69
70     with tqdm(desc="Contando filas totales", unit='filas'
71               ) as pbar:
72         total_rows = 0
73         for chunk in pd.read_csv(csv_file, usecols=[column
74             ], chunksize=chunksize):
75             total_rows += len(chunk)
76             pbar.update(len(chunk))

77     with tqdm(total=total_rows, desc="Procesando datos",
78               unit='filas') as pbar:
79         for chunk in pd.read_csv(csv_file, usecols=[column
80             ], chunksize=chunksize):
81             counter.update(chunk[column].dropna().astype(
82                             str))
83             pbar.update(len(chunk))

84     frequencies = pd.Series(counter)
85     total_unique = len(frequencies)
```

```
84     print(f"\nDatos procesados - Total valores únicos:{\n        format_count(total_unique)})")\n\n85     print("\nClasificando frecuencias...")\n86     with tqdm(total=4, desc="Progreso") as pbar:\n87         low_freq = frequencies[(frequencies >= 1) & (\n            frequencies <= 99)]\n88         pbar.update(1)\n89         mid_freq = frequencies[(frequencies >= 100) & (\n            frequencies <= 1000)]\n90         pbar.update(1)\n91         high_freq = frequencies[(frequencies >= 1001) & (\n            frequencies <= 10000)]\n92         pbar.update(1)\n93\n94         low_bin = list(range(1, 100, 10)) + [100]\n95         mid_bin = list(range(100, 1001, 100)) + [1001]\n96         high_bin = list(range(1001, 10001, 1000)) + [10001]\n97\n98         print("\n====Resumen de frecuencias====")\n99         print(f"\nRango 1-99 repeticiones:")\n100        print(f"Valores únicos:{format_count(len(low_freq))}\n            )}u({len(low_freq)/total_unique:.1%})")\n101\n102        print(f"\nRango 100-1000 repeticiones:")\n103        print(f"Valores únicos:{format_count(len(mid_freq))}\n            )}u({len(mid_freq)/total_unique:.1%})")\n104\n105        print(f"\nRango 1001-10000 repeticiones:")\n106        print(f"Valores únicos:{format_count(len(\n            high_freq))}u({len(high_freq)/total_unique:.1%})")\n107\n108\n109\n110        print("\nGenerando graficos...")\n111        with tqdm(total=3, desc="Progreso") as pbar:\n112            low_path = create_histogram(\n113                low_freq,\n114                bins=low_bin,\n115                title="Distribucion de Frecuencias (1-99)\n                    repeticiones",\n116                filename=f"histograma_1-99_{column}_\n                    {filename_base}.png",\n117                color='#4C72B0'\n118            )\n119            pbar.update(1)\n120\n121            mid_path = create_histogram(\n122                mid_freq,\n123                bins=mid_bin,\n124                title="Distribucion de Frecuencias (100-1000)\n                    repeticiones",\n125                color='#4C72B0'\n126            )\n127            pbar.update(1)\n128\n129            high_path = create_histogram(\n130                high_freq,\n131                bins=high_bin,\n132                title="Distribucion de Frecuencias (1001-10000)\n                    repeticiones",\n133                color='#4C72B0'\n134            )\n135            pbar.update(1)\n136\n137            print(f"\nGraficos generados en el directorio {os.getcwd()}\n            )}u({len(mid_path)}\n            )}u({len(high_path)}\n            )}u({len(low_path)}")\n138\n139\n140\n141\n142\n143\n144\n145\n146\n147\n148\n149\n150\n151\n152\n153\n154\n155\n156\n157\n158\n159\n160\n161\n162\n163\n164\n165\n166\n167\n168\n169\n170\n171\n172\n173\n174\n175\n176\n177\n178\n179\n180\n181\n182\n183\n184\n185\n186\n187\n188\n189\n190\n191\n192\n193\n194\n195\n196\n197\n198\n199\n200\n201\n202\n203\n204\n205\n206\n207\n208\n209\n210\n211\n212\n213\n214\n215\n216\n217\n218\n219\n220\n221\n222\n223\n224\n225\n226\n227\n228\n229\n230\n231\n232\n233\n234\n235\n236\n237\n238\n239\n240\n241\n242\n243\n244\n245\n246\n247\n248\n249\n250\n251\n252\n253\n254\n255\n256\n257\n258\n259\n260\n261\n262\n263\n264\n265\n266\n267\n268\n269\n270\n271\n272\n273\n274\n275\n276\n277\n278\n279\n280\n281\n282\n283\n284\n285\n286\n287\n288\n289\n290\n291\n292\n293\n294\n295\n296\n297\n298\n299\n300\n301\n302\n303\n304\n305\n306\n307\n308\n309\n310\n311\n312\n313\n314\n315\n316\n317\n318\n319\n320\n321\n322\n323\n324\n325\n326\n327\n328\n329\n330\n331\n332\n333\n334\n335\n336\n337\n338\n339\n340\n341\n342\n343\n344\n345\n346\n347\n348\n349\n350\n351\n352\n353\n354\n355\n356\n357\n358\n359\n360\n361\n362\n363\n364\n365\n366\n367\n368\n369\n370\n371\n372\n373\n374\n375\n376\n377\n378\n379\n380\n381\n382\n383\n384\n385\n386\n387\n388\n389\n390\n391\n392\n393\n394\n395\n396\n397\n398\n399\n400\n401\n402\n403\n404\n405\n406\n407\n408\n409\n410\n411\n412\n413\n414\n415\n416\n417\n418\n419\n420\n421\n422\n423\n424\n425\n426\n427\n428\n429\n430\n431\n432\n433\n434\n435\n436\n437\n438\n439\n440\n441\n442\n443\n444\n445\n446\n447\n448\n449\n450\n451\n452\n453\n454\n455\n456\n457\n458\n459\n460\n461\n462\n463\n464\n465\n466\n467\n468\n469\n470\n471\n472\n473\n474\n475\n476\n477\n478\n479\n480\n481\n482\n483\n484\n485\n486\n487\n488\n489\n490\n491\n492\n493\n494\n495\n496\n497\n498\n499\n500\n501\n502\n503\n504\n505\n506\n507\n508\n509\n510\n511\n512\n513\n514\n515\n516\n517\n518\n519\n520\n521\n522\n523\n524\n525\n526\n527\n528\n529\n530\n531\n532\n533\n534\n535\n536\n537\n538\n539\n540\n541\n542\n543\n544\n545\n546\n547\n548\n549\n550\n551\n552\n553\n554\n555\n556\n557\n558\n559\n560\n561\n562\n563\n564\n565\n566\n567\n568\n569\n570\n571\n572\n573\n574\n575\n576\n577\n578\n579\n580\n581\n582\n583\n584\n585\n586\n587\n588\n589\n590\n591\n592\n593\n594\n595\n596\n597\n598\n599\n600\n601\n602\n603\n604\n605\n606\n607\n608\n609\n610\n611\n612\n613\n614\n615\n616\n617\n618\n619\n620\n621\n622\n623\n624\n625\n626\n627\n628\n629\n630\n631\n632\n633\n634\n635\n636\n637\n638\n639\n640\n641\n642\n643\n644\n645\n646\n647\n648\n649\n650\n651\n652\n653\n654\n655\n656\n657\n658\n659\n660\n661\n662\n663\n664\n665\n666\n667\n668\n669\n670\n671\n672\n673\n674\n675\n676\n677\n678\n679\n680\n681\n682\n683\n684\n685\n686\n687\n688\n689\n690\n691\n692\n693\n694\n695\n696\n697\n698\n699\n700\n701\n702\n703\n704\n705\n706\n707\n708\n709\n710\n711\n712\n713\n714\n715\n716\n717\n718\n719\n720\n721\n722\n723\n724\n725\n726\n727\n728\n729\n730\n731\n732\n733\n734\n735\n736\n737\n738\n739\n740\n741\n742\n743\n744\n745\n746\n747\n748\n749\n750\n751\n752\n753\n754\n755\n756\n757\n758\n759\n760\n761\n762\n763\n764\n765\n766\n767\n768\n769\n770\n771\n772\n773\n774\n775\n776\n777\n778\n779\n7710\n7711\n7712\n7713\n7714\n7715\n7716\n7717\n7718\n7719\n7720\n7721\n7722\n7723\n7724\n7725\n7726\n7727\n7728\n7729\n7730\n7731\n7732\n7733\n7734\n7735\n7736\n7737\n7738\n7739\n7740\n7741\n7742\n7743\n7744\n7745\n7746\n7747\n7748\n7749\n77410\n77411\n77412\n77413\n77414\n77415\n77416\n77417\n77418\n77419\n77420\n77421\n77422\n77423\n77424\n77425\n77426\n77427\n77428\n77429\n77430\n77431\n77432\n77433\n77434\n77435\n77436\n77437\n77438\n77439\n77440\n77441\n77442\n77443\n77444\n77445\n77446\n77447\n77448\n77449\n77450\n77451\n77452\n77453\n77454\n77455\n77456\n77457\n77458\n77459\n77460\n77461\n77462\n77463\n77464\n77465\n77466\n77467\n77468\n77469\n77470\n77471\n77472\n77473\n77474\n77475\n77476\n77477\n77478\n77479\n77480\n77481\n77482\n77483\n77484\n77485\n77486\n77487\n77488\n77489\n77490\n77491\n77492\n77493\n77494\n77495\n77496\n77497\n77498\n77499\n774100\n774101\n774102\n774103\n774104\n774105\n774106\n774107\n774108\n774109\n774110\n774111\n774112\n774113\n774114\n774115\n774116\n774117\n774118\n774119\n774120\n774121\n774122\n774123\n774124\n774125\n774126\n774127\n774128\n774129\n774130\n774131\n774132\n774133\n774134\n774135\n774136\n774137\n774138\n774139\n774140\n774141\n774142\n774143\n774144\n774145\n774146\n774147\n774148\n774149\n774150\n774151\n774152\n774153\n774154\n774155\n774156\n774157\n774158\n774159\n774160\n774161\n774162\n774163\n774164\n774165\n774166\n774167\n774168\n774169\n774170\n774171\n774172\n774173\n774174\n774175\n774176\n774177\n774178\n774179\n774180\n774181\n774182\n774183\n774184\n774185\n774186\n774187\n774188\n774189\n774190\n774191\n774192\n774193\n774194\n774195\n774196\n774197\n774198\n774199\n774200\n774201\n774202\n774203\n774204\n774205\n774206\n774207\n774208\n774209\n774210\n774211\n774212\n774213\n774214\n774215\n774216\n774217\n774218\n774219\n774220\n774221\n774222\n774223\n774224\n774225\n774226\n774227\n774228\n774229\n774230\n774231\n774232\n774233\n774234\n774235\n774236\n774237\n774238\n774239\n774240\n774241\n774242\n774243\n774244\n774245\n774246\n774247\n774248\n774249\n774250\n774251\n774252\n774253\n774254\n774255\n774256\n774257\n774258\n774259\n774260\n774261\n774262\n774263\n774264\n774265\n774266\n774267\n774268\n774269\n774270\n774271\n774272\n774273\n774274\n774275\n774276\n774277\n774278\n774279\n774280\n774281\n774282\n774283\n774284\n774285\n774286\n774287\n774288\n774289\n774290\n774291\n774292\n774293\n774294\n774295\n774296\n774297\n774298\n774299\n774300\n774301\n774302\n774303\n774304\n774305\n774306\n774307\n774308\n774309\n774310\n774311\n774312\n774313\n774314\n774315\n774316\n774317\n774318\n774319\n774320\n774321\n774322\n774323\n774324\n774325\n774326\n774327\n774328\n774329\n774330\n774331\n774332\n774333\n774334\n774335\n774336\n774337\n774338\n774339\n774340\n774341\n774342\n774343\n774344\n774345\n774346\n774347\n774348\n774349\n774350\n774351\n774352\n774353\n774354\n774355\n774356\n774357\n774358\n774359\n774360\n774361\n774362\n774363\n774364\n774365\n774366\n774367\n774368\n774369\n774370\n774371\n774372\n774373\n774374\n774375\n774376\n774377\n774378\n774379\n774380\n774381\n774382\n774383\n774384\n774385\n774386\n774387\n774388\n774389\n774390\n774391\n774392\n774393\n774394\n774395\n774396\n774397\n774398\n774399\n774400\n774401\n774402\n774403\n774404\n774405\n774406\n774407\n774408\n774409\n774410\n774411\n774412\n774413\n774414\n774415\n774416\n774417\n774418\n774419\n774420\n774421\n774422\n774423\n774424\n774425\n774426\n774427\n774428\n774429\n774430\n774431\n774432\n774433\n774434\n774435\n774436\n774437\n774438\n774439\n774440\n774441\n774442\n774443\n774444\n774445\n774446\n774447\n774448\n774449\n774450\n774451\n774452\n774453\n774454\n774455\n774456\n774457\n774458\n774459\n774460\n774461\n774462\n774463\n774464\n774465\n774466\n774467\n774468\n774469\n774470\n774471\n774472\n774473\n774474\n774475\n774476\n774477\n774478\n774479\n774480\n774481\n774482\n774483\n774484\n774485\n774486\n774487\n774488\n774489\n774490\n774491\n774492\n774493\n774494\n774495\n774496\n774497\n774498\n774499\n774500\n774501\n774502\n774503\n774504\n774505\n774506\n774507\n774508\n774509\n774510\n774511\n774512\n774513\n774514\n774515\n774516\n774517\n774518\n774519\n774520\n774521\n774522\n774523\n774524\n774525\n774526\n774527\n774528\n774529\n774530\n774531\n774532\n774533\n774534\n774535\n774536\n774537\n774538\n774539\n774540\n774541\n774542\n774543\n774544\n774545\n774546\n774547\n774548\n774549\n774550\n774551\n774552\n774553\n774554\n774555\n774556\n774557\n774558\n774559\n774560\n774561\n774562\n774563\n774564\n774565\n774566\n774567\n774568\n774569\n774570\n774571\n774572\n774573\n774574\n774575\n774576\n774577\n774578\n774579\n774580\n774581\n774582\n774583\n774584\n774585\n774586\n774587\n774588\n774589\n774590\n774591\n774592\n774593\n774594\n774595\n774596\n774597\n774598\n774599\n774600\n774601\n774602\n774603\n774604\n774605\n774606\n774607\n774608\n774609\n774610\n774611\n774612\n774613\n774614\n774615\n774616\n774617\n774618\n774619\n774620\n774621\n774622\n774623\n774624\n774625\n774626\n774627\n774628\n774629\n774630\n774631\n774632\n774633\n774634\n774635\n774636\n774637\n774638\n774639\n774640\n774641\n774642\n774643\n774644\n774645\n774646\n774647\n774648\n774649\n774650\n774651\n774652\n774653\n774654\n774655\n774656\n774657\n774658\n774659\n774660\n774661\n774662\n774663\n774664\n774665\n774666\n774667\n774668\n774669\n774670\n774671\n774672\n774673\n774674\n774675\n774676\n774677\n774678\n774679\n774680\n774681\n774682\n774683\n774684\n774685\n774686\n774687\n774688\n774689\n774690\n774691\n774692\n774693\n774694\n774695\n774696\n774697\n774698\n774699\n774700\n774701\n774702\n774703\n774704\n774705\n774706\n774707\n774708\n774709\n774710\n774711\n774712\n774713\n774714\n774715\n774716\n774717\n774718\n774719\n774720\n774721\n774722\n774723\n774724\n774725\n774726\n774727\n774728\n774729\n774730\n774731\n774732\n774733\n774734\n774735\n774736\n774737\n774738\n774739\n774740\n774741\n774742\n774743\n774744\n774745\n774746\n774747\n774748\n774749\n774750\n774751\n774752\n774753\n774754\n774755\n774756\n774757\n774758\n774759\n774760\n774761\n774762\n774763\n774764\n774765\n774766\n774767\n774768\n774769\n774770\n774771\n774772\n774773\n774774\n774775\n774776\n774777\n774778\n774779\n774780\n774781\n774782\n774783\n774784\n774785\n774786\n774787\n774788\n774789\n774790\n774791\n774792\n774793\n774794\n774795\n774796\n774797\n774798\n774799\n774800\n774801\n774802\n774803\n774804\n774805\n774806\n774807\n774808\n774809\n774810\n774811\n774812\n774813\n774814\n774815\n774816\n774817\n774818\n774819\n774820\n774821\n774822\n774823\n774824\n774825\n774826\n774827\n774828\n774829\n774830\n774831\n774832\n774833\n774834\n774835\n774836\n774837\n774838\n774839\n774840\n774841\n774842\n774843\n774844\n774845\n774846\n774847\n774848\n774849\n774850\n774851\n774852\n774853\n774854\n774855\n774856\n774857\n774858\n774859\n774860\n774861\n774862\n774863\n774864\n774865\n774866\n774867\n774868\n774869\n774870\n774871\n774872\n774873\n774874\n774875\n774876\n774877\n774878\n774879\n774880\n774881\n774882\n774883\n774884\n774885\n774886\n774887\n774888\n774889\n774890\n774891\n774892\n774893\n774894\n774895\n774896\n774897\n774898\n774899\n774900\n774901\n774902\n774903\n774904\n774905\n774906\n774907\n774908\n774909\n774910\n774911\n774912\n774913\n774914\n774915\n774916\n774917\n774918\n774919\n774920\n774921\n774922\n774923\n774924\n774925\n774926\n774927\n774928\n774929\n774930\n774931\n774932\n774933\n774934\n774935\n774936\n774937\n774938\n774939\n774940\n774941\n774942\n774943\n774944\n774945\n774946\n774947\n774948\n774949\n774950\n774951\n774952\n774953\n774954\n774955\n774956\n774957\n774958\n774959\n774960\n774961\n774962\n774963\n774964\n774965\n774966\n774967\n774968\n774969\n774970\n774971\n774972\n774973\n774974\n774975\n774976\n774977\n774978\n774979\n774980\n774981\n774982\n774983\n774984\n774985\n774986\n774987\n774988\n774989\n774990\n774991\n774992\n774993\n774994\n774995\n774996\n774997\n774998\n774999\n7741000\n7741001\n7741002\n7741003\n7741004\n7741005\n7741006\n7741007\n7741008\n7741009\n7741010\n7741011\n7741012\n7741013\n7741014\n7741015\n7741016\n7741017\n7741018\n7741019\n7741020\n7741021\n7741022\n7741023\n7741024\n7741025\n7741026\n7741027\n7741028\n7741029\n7741030\n7741031\n7741032\n7741033\n7741034\n7741035\n7741036\n7741037\n7741038\n7741039\n7741040\n7741041\n7741042\n7741043\n7741044\n7741045\n7741046\n7741047\n7741048\n7741049\n7741050\n7741051\n7741052\n7741053\n7741054\n7741055\n7741056\n7741057\n7741058\n7741059\n7741060\n7741061\n7741062\n7741063\n7741064\n7741065\n7741066\n7741067\n7741068\n7741069\n7741070\n7741071\n7741072\n7741073\n7741074\n7741075\n7741076\n7741077\n7741078\n7741079\n7741080\n7741081\n7741082\n7741083\n7741084\n7741085\n7741086\n7741087\n7741088\n7741089\n7741090\n7741091\n7741092
```

```
125         filename=f"histograma_100-1k_{column}_{"  
126             filename_base}.png",  
127             color='#55A868',  
128             log_scale=True  
129     )  
130     pbar.update(1)  
131  
131     high_path = create_histogram(  
132         high_freq,  
133         bins=high_bin,  
134         title="Distribucion de Frecuencias (1001-10,000  
135             _repeticiones)",  
136         filename=f"histograma_1k-10k_{column}_{"  
137             filename_base}.png",  
138             color='#C44E52',  
139             log_scale=True  
140     )  
141     pbar.update(1)  
142  
142     print("\nGraficos generados exitosamente:")  
143     print(f"{low_path}")  
143     print(f"{mid_path}")  
144     print(f"{high_path}")  
145  
146     if __name__ == "__main__":  
147         main()
```

Código B.7: identifier.histogram\_detailed.py, análisis de frecuencias de la columna 'identifier'.

```
1      import dask.dataframe as dd
2      import sys
3      import os
4
5      def delete_duplicates(input_file, output_file):
6
7          ddf = dd.read_csv(input_file)
8
9          print(f"\nProcesando archivo:{input_file}")
10         print(f"Numero inicial de registros:{len(ddf):,}")
11
12         ddf_deduplicate = ddf.drop_duplicates(
13             subset=['identifier', 'timestamp', 'device_lon',
14                     'device_lat'],
15             keep='first'
16         )
17
18         print(f"Numero de registros despues de eliminar
19               duplicados:{len(ddf_deduplicate):,}")
20
21         ddf_deduplicate.to_csv(
22             output_file,
23             index=False,
24             single_file=True
25         )
26
27         print(f"\nArchivo sin duplicados guardado en:{output_file}")
28
29     if __name__ == "__main__":
30         if len(sys.argv) < 2:
31             print("Error: Debe especificar un archivo CSV como
32                   argumento")
33             sys.exit(1)
34
35         input_csv = sys.argv[1]
36         base_name = os.path.splitext(input_csv)[0]
37         output_csv = f"{base_name}_DeDuplicate.csv"
38
39         delete_duplicates(input_csv, output_csv)
```

Código B.8: csv\_deduplicate.py, eliminación de duplicados en el conjunto de datos.

```
1      import os
2      import pandas as pd
3      import matplotlib.pyplot as plt
4      import numpy as np
5      from collections import Counter
6      import sys
7      from tqdm import tqdm
8      import math
9      from datetime import datetime
10
11     def format_count(count):
12         if count >= 1_000_000:
13             return f"{count/1_000_000:.1f}M"
14         elif count >= 1_000:
15             return f"{count/1_000:.1f}K"
16         return str(count)
17
18     def main():
19         if len(sys.argv) < 2:
20             print("Error: Debe especificar un archivo CSV como argumento")
21             sys.exit(1)
22
23         csv_file = sys.argv[1]
24         filename = os.path.splitext(os.path.basename(csv_file))[0]
25         identifier_col = "identifier"
26         timestamp_col = "timestamp"
27         chunksize = 1_000_000
28
29         print(f"\nIniciando procesamiento del archivo: {csv_file}")
30         print(f"Columnas analizadas: {identifier_col} y {timestamp_col}")
31
32         os.makedirs("img/daily_histograms", exist_ok=True)
33         print("Directorios 'img/daily_histograms' verificados/creados")
34
35         print("\nProcesando datos y agrupando por dia...")
36
37         date_freqs = {}
38         max_freq = 0
39
40         total_chunks = sum(1 for _ in pd.read_csv(csv_file,
41                           usecols=[timestamp_col, identifier_col], chunksize=
42                           chunksize))
43
44         with tqdm(total=total_chunks, unit='chunk') as pbar:
```

```
44         for chunk in pd.read_csv(csv_file, usecols=[  
45             timestamp_col, identifier_col], chunksize=  
46             chunksize):  
47             try:  
48                 chunk['date'] = pd.to_datetime(  
49                     chunk[timestamp_col],  
50                     format='mixed',  
51                     errors='coerce'  
52                 ).dt.date  
53  
54                 chunk = chunk.dropna(subset=['date'])  
55  
56                 for date, group in chunk.groupby('date'):  
57                     if date not in date_freqs:  
58                         date_freqs[date] = Counter()  
59  
60                     date_freqs[date].update(group[  
61                         identifier_col].dropna().astype(str)  
62                     )  
63  
64                     current_max = date_freqs[date].  
65                     most_common(1)[0][1] if date_freqs[  
66                         date] else 0  
67                     if current_max > max_freq:  
68                         max_freq = current_max  
69                 except Exception as e:  
70                     print(f"\nError al procesando chunk: {str(e)}")  
71                     continue  
72                 finally:  
73                     pbar.update(1)  
74  
75             if not date_freqs:  
76                 print("\nError: No se encontraron datos validos  
77                     para procesar")  
78                 sys.exit(1)  
79  
80             bins = [0] + [10**i for i in range(0, int(np.log10(  
81                 max_freq)) + 2)] if max_freq > 0 else [0, 1]  
82  
83             print("\nGenerando histogramas por dia...")  
84  
85             for date, counter in tqdm(date_freqs.items(), total=len(  
86                 date_freqs), unit='dia'):  
87                 frecuencia = pd.Series(counter)  
88                 total_unique_values = len(frecuencia)  
89                 total_occurrence = frecuencia.sum()  
90  
91                 group_freq = pd.cut(frecuencia, bins=bins, right=  
92                     False).value_counts().sort_index()  
93                 percentage_per_range = (group_freq /
```

```
84         total_unique_values * 100).round(2)
85
86     plt.figure(figsize=(16, 9))
87     ax = group_freq.plot(kind='bar', logy=True, alpha
88                           =0.7, edgecolor='black')
89
90     formatted_labels = []
91     for interval in group_freq.index.categories:
92         left = int(interval.left)
93         right = int(interval.right - 1)
94         formatted_labels.append(f'{left}-{right}' if
95                               left != right else f'{left}')
96
97     plt.xticks(range(len(formatted_labels)),
98                formatted_labels, rotation=45, ha='right')
99
100    date_str = date.strftime('%Y-%m-%d')
101    plt.title(f"Histograma de Frecuencias de
102              Identificadores\nArchivo:{filename} - Fecha:{date_str}",
103              fontsize=16, pad=20)
104    plt.xlabel("Rango de Frecuencia", fontsize=14)
105    plt.ylabel("Cantidad de Valores Únicos (log)",
106               fontsize=14)
107    plt.grid(True, which="both", ls="--", axis='y')
108
109    stats_text = (
110        f"Total valores únicos:{(total_unique_values)
111         : ,}\n"
112        f"Total ocurrencias:{(total_occurrence): ,}\n"
113        f"Frecuencia máxima:{(frequency.max()): ,}"
114    )
115    plt.annotate(stats_text,
116                  xy=(0.95, 0.95),
117                  xycoords='axes fraction',
118                  fontsize=15,
119                  ha='right',
120                  va='top',
121                  bbox=dict(boxstyle='round', facecolor=
122                             'white', alpha=0.9))
123
124    max_val = group_freq.max()
125    min_y = 0.9
126
127    for i, (count, porcent) in enumerate(zip(group_freq
128                                              .values, percentage_per_range.values)):
129        if count > 0:
130            y_pos = count * 1.1 if count * 1.1 > min_y
131            else min_y * 1.2
132            text = f"{porcent}\n{format_count(count)
133                  }"
134            ax.text(
```

```
123             i, y_pos, text,
124             ha='center', va='bottom',
125             fontsize=15,
126             fontweight='bold',
127             bbox=dict(
128                 facecolor='white',
129                 alpha=0.85,
130                 edgecolor='lightgray',
131                 boxstyle='round', pad=0.3,
132             )
133         )
134
135     output_path = os.path.join("img", "daily_histograms",
136                               f"histograma_{identifier_col}_{filename}_{date_str}.png")
137     plt.tight_layout()
138     plt.savefig(output_path, dpi=300, bbox_inches='tight')
139     plt.close()
140
141     print("\nHistogramas generados exitosamente")
142     print(f"Archivos guardados en: img/daily_histograms/")
143     print(f"Total días procesados: {len(date_freqs)}")
144     print(f"Frecuencia máxima global encontrada: {format_count(max_freq)}\n")
145
146 if __name__ == "__main__":
147     main()
```

Código B.9: identifier\_histogram\_daily.py, análisis de frecuencias de la columna 'identifier' por día.

## **Referencias**

---

- [1] Autor referencia 1
- [2] Autor referencia 2
- [3] Autor referencia 3